

Lezione 5

INTRODUZIONE ALLE TABELLE HASH E FUNZIONI HASH

Una tabella hash è una struttura dati efficace nell'implementare dizionari. Questa struttura dati supporta infatti le operazioni **INSERT, SEARCH, DELETE**.

Una tabella hash, in genere, impiega un array di dimensione proporzionale al numero di dati memorizzati, che è relativamente piccola rispetto al numero di chiavi possibili.

L'efficienza delle tabelle hash è legata all'uso di funzioni hash che abbiano opportune proprietà.

Notazioni:

U : universo delle chiavi

U

K : chiavi memorizzate, $|K| = n$

m : dimensione delle tabelle (# slot).

DEF: Una **funzione hash** mappa l'universo U delle chiavi negli slot di una tabella $T[0, 1, \dots, m-1]$

$h: U \rightarrow \{0, 1, \dots, m-1\}$


$h \mapsto h(k)$ (chiama $h(k)$ l'hash di k)

(l'elemento con chiave k è memorizzato nello slot $h(k)$).

In generale, $m \ll |U|$.

Esempio : $h: U \rightarrow \{0, \dots, m\}$, $h(k) = k \bmod (m)$.

OSS: Due chiavi possono avere lo stesso hash, ovvero possono $\exists k_1, k_2 \in U : h(k_1) = h(k_2)$. In tal caso diciamo che k_1 e k_2 **collidono**.



E tuttavia totalmente le collisioni è impossibile. Perché abbiamo bisogno di risolvere.

Risolvere mediante chaining (concatenazione): L'insieme delle chiavi è suddiviso su sottoinsiemi di dimensione $\frac{m}{n}$.

Le funzioe hash determina a quale sottoinsieme appartiene una chiave. Ogni sottoinsieme è gestito indipendentemente come una lista.

Una funzione hash bien construite contribuisce a evitare le collisioni.



Una funzione hash **perfette** e **indipendente** è tale che $\forall k \in U$, $h(k)$ sia scelto in modo che la funzione è indipendente

da $\{0, 1, \dots, m-1\}$.

uniforme: $\forall k \in U \quad \forall j \in \{0, \dots, m-1\} \quad \Pr[h(k)=j] = \frac{1}{m};$

indipendente: $\forall k_1, k_2 \in U, k_1 \neq k_2 \quad \forall j_1, j_2 \in \{0, \dots, m-1\}$

$$\Pr[h(k_1)=j_1 \mid h(k_2)=j_2] = \Pr[h(k_1)=j_1]$$

o, equivalentemente

$$\Pr[h(k_1)=j_1 \wedge h(k_2)=j_2] = \Pr[h(k_1)=j_1] \Pr[h(k_2)=j_2].$$

Una funzione di hash indipendente e uniforme viene anche chiamata random oracle.

Le funzioni di hash indipendente e uniforme sono una astrazione teorica, ma sono difficili da implementare in pratica. Tuttavia, è possibile avere funzioni di hashing che sono approssimativamente uniformi e indipendenti.

Per l'utilizzo degli algoritmi di ricerca nelle tabelle hash conviene usare l'hashing uniforme e indipendente.

fattore di carico

$$\alpha = \frac{n}{m} \quad \left(\begin{array}{l} \text{\# medie di elementi} \\ \text{nello stesso slot} \end{array} \right)$$

OSS: Nel caso di tabelle hash dove le collisioni sono esatte per concordanze $\alpha \leq 1$.

Se una tabella ha le ~~caselle~~ cellule aperte, ogni elemento della tabella contiene o un elemento dell'insieme diverso o NIL. Le tabelle ha le a ~~caselle~~ cellule aperte possono essere riempite così da uscire nuovo funzionamento e possibile ovvero il fattore di carico vale più di 1.

Quando un elemento deve essere inserito nelle tabelle, viene allocato nella posizione "punto scelto". Se la posizione è già occupata il nuovo elemento è allocato nella posizione di "secondo salto" e così via

Per cercare un elemento bisogna eseguire questo iterazione gli slot nell'ordine prefissato relativo all'elemento, finché si trova l'elemento cercato o si trova uno slot nullo, in quest'ultimo caso si ha una ricerca senza successo.

Il vantaggio dell'indirizzamento aperto è che si evita del tutto i puntatori.

Nell'ambito degli algoritmi di ricerca su una tabella ha le a ~~caselle~~ cellule aperte, assicurando che la funzione di hashing sia un ~~hashing di~~ hash funzione indipendente e uniforme.

Hashing di permutazioni

→ sono un!

$h: K \longrightarrow$ Permutazioni di $\{0, \dots, m-1\} = \{G_1, \dots, G_m\}$

$h(k) = \{h(k, 1), \dots, h(k, m)\}$

\downarrow
primo
scelto

\downarrow
m-esimo
scelto

Una hashing di permutazioni uniforme e indipendente è tale che
 $\forall k \in U$, $h(k)$ sia scelto tra m numeri uniforme e indipendente
da $\{G_1, \dots, G_m\}$

uniforme: $\forall k \in U \forall G$ permutazioni
di $\{0, \dots, m-1\}$, $\Pr[h(k) = G] = \frac{1}{m!}$;

indipendente: $\forall k_1, k_2 \in U, k_1 \neq k_2, \forall G_1, G_2$ permutazioni di $\{0, \dots, m-1\}$

$$\Pr[h(k_1) = G_1 \mid h(k_2) = G_2] = \Pr[h(k_1) = G_1]$$

o, equivalentemente

$$\Pr[h(k_1) = G_1 \wedge h(k_2) = G_2] = \Pr[h(k_1) = G_1] \Pr[h(k_2) = G_2]$$

OSS: Nelle tabelle hash a raddrizzamento aperto $m \leq n \Rightarrow \alpha \leq 1$.